



maftools 文档

部门：医学科研事业部-人重


二零二二年

目录

1.引言	3
2.MAF 格式.....	4
3.maftools 总体框架	6
4.运行过程	7
4.1 plotmafSummary.....	8
4.2 oncoplot.....	12
4.3 somaticInteractions.....	15
4.4 oncodrive	16
4.5 OncogenicPathways	17
4.6 tcgaCompare.....	18
4.7 Titv	19
4.8 lollipopPlot.....	20
4.9 geneCloud.....	21
附表一：TCGA 癌症缩写对照表.....	22

1.引言

2022 年，国家癌症中心发布了最新一期的全国癌症统计数据，这是自 2019 年后，国家癌症中心首次权威更新公布全国恶性肿瘤的发病与死亡率。此次数据是从全国 682 个癌症监测点中遴选 487 个高质量监测点，覆盖人口达 3.8 亿，详细阐述了 2016 年中国癌症疾病负担情况。由于人口老龄化的加剧，预计 2040 年相比 2020 年，癌症负担将增加 50%，届时全新新发癌症病例数将达到近 3000 万。



2016 年，全国新发癌症病例 406.4 万例，其中男性 223.4 万例，女性 183 万例。

五大高发癌症依次是肺癌（82.8 万例）、结直肠癌（40.8 万例）、胃癌（39.7 万例）、肝癌（38.9 万例）、乳腺癌（30.6 万例）。

参考文献:

Zheng RS, Zhang SW, Zeng HM, Wang SM, Sun KX, Chen R, Li L, Wei WQ, He J. Cancer incidence and mortality in China, 2016[J]. JNCC, 2022, 2(1): 1-9.

2.MAF 格式

MAF, Mutation Annotation Format, 是由 TCGA 指定的一种文件格式, 用来存储突变注释信息, MAF 用于整合所有样本的体细胞突变注释结果。

MAF 是专门针对 human 定义的一种文件格式, 通过一个文件就可以包含所有样本的 SNV 和对应的注释信息。MAF 是一个纯文本的格式, 由“\t”分割的许多列构成。

Hugo_Symbol	由 HUGO 提供的 gene symbol, 表示 SNV 所在的基因名称
Entrez_Gene_id	SNV 所在基因的 entrez id
NCBI_Build	snv calling 时使用的参考基因组版本
Chromosome	SNV 所在的染色体
Start_Position	SNV 在染色体上的起始位置
End_Position	SNV 在染色体上的终止位置
Variant_Classification	SNV 位点的分类, Missense_Mutation, Nonsense_Mutation 等类别,
Variant_Type	SNV 位点的类型, 比如 SNP,INS,DEL 等类型
Reference_Allel	参考基因组上的 allele
Tumor_Seq_Allel1	肿瘤样本中该位点对应的主等位基因
Tumor_Seq_Allel2	肿瘤样本中该位点对应的次等位基因
Tumor_Sample_Barcode	肿瘤样本的 barcode
Tumor_Normal_Barcode	配对的正常样本的 barcode

详细 MAF 格式, 参考网址: https://docs.gdc.cancer.gov/Data/File_Formats/MAF_Format/

```
library(maftools)
```

```
laml = read.maf(maf = maffile)
```

参数解释:

```
laml #运行 laml 查看 MAF 的基本汇总信息.
```

```
> laml
An object of class MAF
      ID summary Mean Median
1:  NCBI_Build GRCh38    NA    NA
2:    Center    ZY    NA    NA
3:   Samples    96    NA    NA
4:    nGenes    67    NA    NA
5: Frame_Shift_Del    7 0.080  0.0
6: Frame_Shift_Ins    1 0.011  0.0
7:   In_Frame_Del   64 0.727  1.0
8:   In_Frame_Ins    2 0.023  0.0
9: Missense_Mutation 162 1.841  2.0
10: Nonsense_Mutation  19 0.216  0.0
11:   Splice_Site     4 0.045  0.0
12:      total    259 2.943  2.5
```

> getSampleSummary(laml) #显示样本汇总信息

```
> getSampleSummary(laml)
      Tumor_Sample_Barcode Frame_Shift_Del Frame_Shift_Ins In_Frame_Del
1:      MwD_7124.T           0           0           0
2:      Hgb_7368.T           1           0           1
3:      TUMOR           1           1           5
4:      Hgb_6147.T           0           0           1
5:      HgC_6128.T           0           0           1
6:      MmD_4159.T           2           0           1
7:      MwB_7037.T           0           0           1
```

> getGeneSummary(laml) # 显示基因汇总信息

```
> getGeneSummary(laml)
      Hugo_Symbol Frame_Shift_Del Frame_Shift_Ins In_Frame_Del In_Frame_Ins
1:      MAP3K1           0           0           59           0
2:      TP53            4           0           1           0
3:      ATRX            2           1           0           0
4:      IDH1            0           0           0           0
5:      ARID1A           0           0           0           2
6:      COL1A1           0           0           0           0
7:      PIK3CA           0           0           0           0
8:      SETD2            0           0           0           0
9:      EGFR             0           0           0           0
```


getFields(laml) #展示 MAF 文件的各个变量

```
> getFields(laml)
[1] "Hugo_Symbol"      "Entrez_Gene_Id"
[3] "Center"          "NCBI_Build"
[5] "Chromosome"      "Start_Position"
[7] "End_Position"    "Strand"
[9] "Variant_Classification" "Variant_Type"
[11] "Reference_Allele" "Tumor_Seq_Allele1"
[13] "Tumor_Seq_Allele2" "dbSNP_RS"
[15] "dbSNP_Val_Status" "Tumor_Sample_Barcode"
[17] "Matched_Norm_Sample_Barcode" "Match_Norm_Seq_Allele1"
[19] "Match_Norm_Seq_Allele2" "Tumor_Validation_Allele1"
[21] "Tumor_Validation_Allele2" "Match_Norm_Validation_Allele1"
[23] "Match_Norm_Validation_Allele2" "Verification_Status"
```

3.maftools 总体框架

随着癌症基因组学的进步，MAF 被广泛接受，并用于存储检测到的体细胞变异。癌症基因组图谱项目(The Cancer Genome Atlas, TCGA)已经对多种不同的癌症进行测序。由体细胞变异组成的结果数据以 MAF 形式存储。maftools 包以有效的方式从 TCGA 或任何内部研究中总结、分析、注释和可视化 MAF 文件。

maftools 函数可以主要分为可视化和分析模块，使用 read.maf 读取 MAF 文件，然后将生成的 MAF 对象传递给所需的函数进行绘图或分析。



官网说明书: <http://bioconductor.org/packages/release/bioc/manuals/maftools/man/maftools.pdf>

输入文件: MAF 格式

3.1 安装 maftools, 使用 bioconductor 安装 R 包

```
if(!requireNamespace("BiocManager", quietly = TRUE))
```

```
  install.packages("BiocManager")
```

```
BiocManager::install("maftools")
```

3.2 导入 maftools 包

```
library(maftools)
```

4.运行过程

将队列中的素有样本进行合并，利用 maftools 软件绘制出整个队列的突变全景图。根据突变在队列中的复发情况，鉴定驱动基因，根据突变在每个样本中的出现情况鉴定突变互斥与突变协同的基因对。

结果如下：

Missense_Mutation	错义突变
Frame_Shift_Del	移码缺失突变
Frame_Shift_Ins	移码插入突变
Nonsense_Mutation	无义突变
Splice_Site	剪切位点
In_Frame_Del	框内缺失
In_Frame_Ins	框内插入
translation_start_site	转录起始位点
nonstop_mutation	终止密码子突变

4.1 plotmafSummary

绘制 MAF 的摘要图，使用 `plotmafSummary` 来绘制 `maf` 文件的摘要，该文件将样本中的突变数量显示为堆叠条形图，将突变类型显示为由 `Variant_Classification` 总结的箱形图。


分析过程：

- 1) 每个样本中的变体数量，来显示为堆叠的条形图；
- 2) 将变量类型，显示为由 `Variant_classification` 分类汇总的箱形图
- 3) 可以将平均值或中值线添加到堆叠条形图中，来显示队列中的平均/中位数变量。

```
png("summary.png", width=1000*2, height=800*2, res=72*2)
```

```
plotmafSummary(maf = laml)
```

```
dev.off()
```



改变颜色，可以设置 `color` 参数

```
vc_cols = RColorBrewer::brewer.pal(n = 8, name = 'Paired') # 使用 RColorBrewer 的颜色
```

```
names(vc_cols) = c (
```




```
'Frame_Shift_Del',
'Missense_Mutation',
'Nonsense_Mutation',
'Multi_Hit',
'Frame_Shift_Ins',
'In_Frame_Ins',
'Splice_Site',
'In_Frame_Del')
```

```
png("summary1.png", width=1000*2, height=800*2, res=72*2)
```

```
plotmafSummary(maf = lam1, color = vc_cols)
```

```
dev.off()
```



```
plotmafSummary (maf = laml, rmOutlier = FALSE, addStat = 'median', dashboard = TRUE,
titvRaw = FALSE, showBarcodes = FALSE, textSize = 6, fs = 1, color = vc_cols, titvColor =
NULL, top = 10, titleSize = c (1.3, 1))
```

参数解释:

addStat = 'median' 用于在每个样本突变数的堆叠图中加入中位数线, 也可以设为 addStat = 'mean'或者不加该线。默认 NULL


dashboard=TRUE 若设置为 FALSE, 则不生成仪表盘模式

titvRaw=FALSE 若设置为 FALSE, 将表示数目而不是比例

top=20 默认显示前 20 个高突变基因, 可设置为其他数字

showBarcodes=TRUE 每个样本突变数目堆叠图将显示样本名

textSize=0.5 设置堆叠图中样本名的大小, 默认 0.8,如果样本数少可以使用默认值, 一旦样本数多需设置较小值。



体细胞突变全景图可视化展示, 展示内容包括"Variant Classification"、"Variant Type"、"SNV Class"、"Variants per sample"、"Variant Classification summary"、"Top 10 mutated

genes"的统计；堆叠的 barplot 展示 maf 文件中每个样本中的变异数量，并添加中位线，以显示队列间的中位数变异数量。箱形图展示 variant_classification 的变异类型。

第一幅图：是不同变异类型频数分布柱状图，根据对蛋白编码的影响划分成了

Missense_Mutation 等 7 个类型；

第二幅图：不同变异类别的频数分布柱状图，分成 SNP、INS 和 DEL 三种类别。

第三幅图：SNV 突变类型的频数分布柱状图，考虑到突变之间的组合和正负链，分成了 6 种类别。

第四幅图：每个样本不同变异类型堆积柱状图，对应第一幅图中的 7 种类型。

第五幅图：不同变异类型在每个样本中分布的箱体图，对应第一幅图的 7 种类型。

第六幅图：突变频率最高的 top10 个基因上不同突变类型的堆积柱状图，对应第一幅图的 7 种类型。

从上图可以看出：

- 1) 当根据不同类别对突变类型进行分类时，错义突变占主要的部分；
- 2) SNP 的出现频率高于插入或缺失，
- 3) C>T 是 SNV 最常见的突变。
- 4) 图中还展示了特定样品中的肿瘤突变负荷以及排名前 10 位的突变基因。

4.2 oncoplot


Oncoplots 绘制瀑布图，侧面条形图 and 顶部条形图可分别由 `drawRowBar` 和 `drawColBar` 参数控制。突变全景图（oncoplots），这里只展示了突变检出率 top10 的基因，参数可以自己调整。展示所有样本的变异情况，比如哪些基因频率较高，哪种类型变异比较多，所有样本突变呈现什么样的 pattern 等。

```
png("Oncoplots1.png",width=1000*2,height=800*2,res=72*2)

oncoplot(maf = laml, top = 15, # 显示前 15 个的突变基因信息

showTumorSampleBarcodes = F) # 不显示病人信息

dev.off()
```



增加相应的参数:

```
oncoplot(maf=laml,top = 15,genes = NULL,drawRowBar = TRUE, drawColBar = TRUE,

clinicalFeatures = NULL,annotationDat = NULL, annotationColor = NULL, genesToIgnore =

NULL,showTumorSampleBarcodes = FALSE, removeNonMutated = TRUE, colors = vc_cols,

sortByMutation = FALSE, sortByAnnotation = FALSE,annotationOrder = NULL,
```

```
keepGeneOrder = FALSE, GeneOrderSort = TRUE, sampleOrder = NULL, writeMatrix =
FALSE, fontSize = 1.3, SampleNamefontSize = 1.5, titleFontSize = 1.5, legendFontSize = 2,
annotationFontSize = 1.5)
```

参数解释:

maf: read.maf()产生的对象

top: 绘制多少个 top 基因，默认 20；可以设置参数‘genes’只展示某几个感兴趣的基因。

colors: 为每一种突变类型定义一种颜色，默认 NULL

removeNonMutated: 设为 TRUE 时会删除不含突变的样本，默认 TRUE

clinicalFeatures: 临床文件中的列名

sortByAnnotation: 设为 TRUE 时将根据临床因素进行排序

showTumorSampleBarcodes: 是否展示样本名/样本 ID


sampleOrder: 按照特异的样本名称排序，默认 NULL

FontSize: 基因名的字体大小

SampleNamefontSize: 样本名字体大小

titleFontSize: 图题头的字体大小

legendFontSize: 图例字体大小



高频突变基因瀑布图可视化展示，按照人群突变频率由高到低展示，图中展示了突变频率 top15 的基因在每个样本中的突变情况。瀑布图：一行代表一个基因，一列为一个样本。


變異注釋為 Multi_Hit 表示同一樣本中突變多次的基因，某个基因在一个样本中突变次数超过 1。

上图图中展示了排名前 15 位的基因在不同样本中的突变情况，各种颜色表示不同的突变类型；图例上方的小节显示了突变负荷。展示的结果显示：

- 1) 共有 96 例（84.38%）样本存在基因突变，
- 2) MAP3K1 基因在患者中的突变频率最高。图的右半部分通过柱形图展示了该基因不同突变类型的占比情况。

oncoplot 可以取其中感兴趣或者研究热点的基因，单独分析特定基因的突变情况。

```
oncoplot(maf=laml, genes = c('TP53', 'PIK3CA', 'MAP3K1'), drawRowBar = TRUE,
drawColBar = TRUE, clinicalFeatures = NULL, annotationDat = NULL, annotationColor =
NULL, genesToIgnore = NULL, showTumorSampleBarcodes = FALSE, removeNonMutated =
TRUE, colors = vc_cols, sortByMutation = FALSE, sortByAnnotation = FALSE, annotationOrder
= NULL, keepGeneOrder = FALSE, GeneOrderSort = TRUE, sampleOrder = NULL, writeMatrix
= FALSE, fontSize = 5, SampleNamefontSize = 5, titleFontSize = 5, legendFontSize = 5,
annotationFontSize = 5)
```



4.3 somaticInteractions

癌症中的许多引起疾病的基因共同发生或在其突变模式中显示出强烈的排他性。可以使用 somaticInteractions 函数使用配对 Fisher's 精确检验来分析突变基因之间的 co-occurring 或者 exclusiveness。


```
somaticInteractions (maf = laml, top = 20, pvalue = c(0.05, 0.1), fontSize = 0.7)
```

参数解释：

top=20: 选取的基因数目，默认 20

pvalue=c(0.05,0.1): 设定的 p-value 上下阈值

fontSize=0.8: 设定基因名称的大小，默认 0.8



从上图可以得到：不同基因突变之间的相关性热图，颜色代表了相应的 P 值，并对 $P < 0.05$ 和 $P < 0.001$ 的进行标记。从图中可以看出：

- 1) TP53 和 ATRX 之间有较强的 Co-occurrence;
- 2) TP53 和 MAP3K1 之间有较强的 Exclusive;

提取 P 值：

```
Interact <- somaticInteractions (maf = laml, top = 20, pvalue = c(0.05, 0.1), fontSize = 0.7)
```

```
Interact$gene_sets
```

```
> Interact$gene_sets
      gene_set      pvalue
1: TP53, MAP3K1, COL1A1 0.005367355
2:  TP53, MAP3K1, IDH1 0.082564192
```

4.4 oncodrive

oncodrive 是一个基于 oncodriveCLUST 算法的函数，从 MAF 文件中预测驱动基因。它是根据：癌症驱动基因的突变一般富集在某些特定的位点（即 hot-spots），然后利用这些位点去鉴定基因。用 plotOncodrive 来绘制这些结果。

```
data_drive <- oncodrive(maf=laml)
```

```
head(data_drive)
```

```
> head(data_drive)
Hugo_Symbol Frame_Shift_Del Frame_Shift_Ins In_Frame_Del In_Frame_Ins
1: IDH1 0 0 0 0
2: MAP3K1 0 0 59 0
3: RUNX1 0 0 0 0
4: ARID1A 0 0 0 2
5: MTOR 0 0 2 0
6: EGFR 0 0 0 0


Missense_Mutation Nonsense_Mutation Splice_Site total MutatedSamples
1: 12 0 0 12 12
2: 0 0 0 59 59
3: 5 0 0 5 5
4: 6 0 0 8 8
5: 3 0 0 5 5
6: 5 0 0 5 5

AlteredSamples clusters muts_in_clusters clusterScores protLen zscore
1: 12 1 12 1.0000000 414 5.5461538
2: 59 1 59 1.0000000 1512 5.5461538
3: 5 2 5 1.0000000 480 5.5461538
4: 8 2 4 0.5000000 2285 1.7000000
5: 4 1 3 0.4707107 2549 1.4746975
6: 5 1 2 0.4000000 1210 0.9307692

pval fdr fract_muts_in_clusters
1: 1.460110e-08 5.353735e-08 1.0
2: 1.460110e-08 5.353735e-08 1.0
3: 1.460110e-08 5.353735e-08 1.0
4: 4.456546e-02 1.225550e-01 0.5
5: 7.014694e-02 1.543233e-01 0.6
6: 1.759865e-01 3.226419e-01 0.4
```

```
drive_v <- oncodrive(maf=laml)
```

```
plotOncodrive(drive_v)
```



图中点的大小对应基因内突变 cluster 的数量。X 轴：cluster 内的突变数量。Y 轴是 $-\log_{10}(\text{fdr})$ 。


4.5 OncogenicPathways

OncogenicPathways 功能查看显著富集通路

OncogenicPathways (maf = laml)

```
> OncogenicPathways (maf = laml)
Pathway alteration fractions
  Pathway  N n_affected_genes fraction_affected
1:  RTK-RAS 85             7      0.08235294
2:    PI3K 29             5      0.17241379
3:    WNT 68             5      0.07352941
4: TGF-Beta 7             3      0.42857143
5:   NOTCH 71             3      0.04225352
6:   NRF2  3             1      0.33333333
7:   TP53  6             1      0.16666667
8:   Hippo 38             1      0.02631579
9: Cell_Cycle 15          0      0.00000000
10:    MYC 13             0      0.00000000
```

PlotOncogenicPathways(maf=laml,pathways="WNT")



其中抑癌基因是红色。


4.6 tcgaCompare

通过 `tcgaCompare` 函数实现 `laml`（自有群体）与 TCGA 中已有的 33 个癌种队列的突变负载情况比较。TCGA 包含 30 多不同的癌症队列，它们之间的中位突变载量从低至 7 个外显子到(嗜铬细胞瘤和肾上腺副神经节瘤)到高达 315 个外显子(皮肤黑色素瘤)不等。看看给定 MAF 中的突变负荷如何与 TCGA 队列相抗衡，这是很有意义的。这可以通过函数 `tcgaCompare` 来实现，该函数绘制从 33 个 TCGA 地标队列中的 10000 多个 WXS 样本编译而成的变异的分布。


```
laml.mutload = tcgaCompare(maf = laml, cohortName = 'our-cohort', logscale = TRUE,
capture_size = 50)
```

参数解释：

`cohortName` 给输入的队列命名



改变颜色 `laml.mutload = tcgaCompare(maf = laml, col = c("blue", "black"))`




横坐标：肿瘤队列，对应不同的肿瘤；纵坐标：该肿瘤队列中每个样本的体细胞突变个数；红色的线：中位数。

4.7 Titv

titv 函数将 SNP 分类为 Transitions and Transversions，并以各种方式返回汇总表的列表。汇总的数据还可以可视化显示六个不同转换的总体分布的 boxplot 图，以及显示每个样本中的转换分数的堆叠条形图。

```
laml.titv = titv(maf = laml, plot = FALSE, useSyn = TRUE)
```

```
plotTiTv(res = laml.titv)
```



统计所有 SNV 中的颠换和转换的数量，并进行可视化。


上方的图：每种突变类型以及颠换，转换的位点在所有样本分布的箱形图。

下方的图：每个样本中不同突变类型的百分比堆积柱状图。

4.8 lollipopPlot

使用 lollipopPlot 函数可以绘制棒棒糖图，用于显示蛋白的结构域以及氨基酸突变的位点和类型。这个功能需要 MAF 文件中有体现氨基酸变化的字段，并通过 AACol 参数进行设定（这个字段通常没有固定的名称）。

```
lollipopPlot(maf=laml, gene="TP53", AACol="HGVSp_Short", showMutationRate=TRUE)
```



默认的情况下，以最长转录本为参考，用圆点表示不同类型变异位点在转录本的位置，用竖线的高度表示变异位点对应的频率。

4.9 geneCloud

geneCloud 可以通过词云的方式按字体大小展示包含突变基因的样本数。

```
geneCloud(input=laml)
```



每个基因的大小与其突变/改变的样品总数成比例。

附表一：TCGA 癌症缩写对照表

Study Abbreviation	Study Name
LAML	Acute Myeloid Leukemia
ACC	Adrenocortical carcinoma
BLCA	Bladder Urothelial Carcinoma
LGG	Brain Lower Grade Glioma
BRCA	Breast invasive carcinoma
CESC	Cervical squamous cell carcinoma and endocervical adenocarcinoma
CHOL	Cholangiocarcinoma
LCML	Chronic Myelogenous Leukemia
COAD	Colon adenocarcinoma
CNTL	Controls
ESCA	Esophageal carcinoma
FPPP	FFPE Pilot Phase II
GBM	Glioblastoma multiforme
HNSC	Head and Neck squamous cell carcinoma
KICH	Kidney Chromophobe
KIRC	Kidney renal clear cell carcinoma
KIRP	Kidney renal papillary cell carcinoma
LIHC	Liver hepatocellular carcinoma
LUAD	Lung adenocarcinoma
LUSC	Lung squamous cell carcinoma
DLBC	Lymphoid Neoplasm Diffuse Large B-cell Lymphoma
MESO	Mesothelioma
MISC	Miscellaneous
OV	Ovarian serous cystadenocarcinoma
PAAD	Pancreatic adenocarcinoma
PCPG	Pheochromocytoma and Paraganglioma

PRAD	Prostate adenocarcinoma
READ	Rectum adenocarcinoma
SARC	Sarcoma
SKCM	Skin Cutaneous Melanoma
STAD	Stomach adenocarcinoma
TGCT	Testicular Germ Cell Tumors
THYM	Thymoma
THCA	Thyroid carcinoma
UCS	Uterine Carcinosarcoma
UCEC	Uterine Corpus Endometrial Carcinoma
UVM	Uveal Melanoma
